

CONTEXTO PARA AGENTES DE IA · PARTE 1

7 confusões que fazem agentes de IA errarem

— e o teste que evita cada uma

André Antero de Carvalho

Por que agentes erram?

Na maioria das vezes, não é o modelo. É o **contexto**: o agente recebeu informação desatualizada, incompleta ou fora de escopo — ou recebeu a informação certa e a leu errado.

Quase toda falha desse tipo é uma **confusão entre duas coisas parecidas**.

> **A IDEIA**
>
> Dar nome à diferença é o primeiro passo para testá-la.

PODE VER ≠ VIU

O ERRO

"A informação estava disponível, então o agente sabia."

O TESTE

Registre o que foi **efetivamente entregue** ao modelo em cada chamada — não o que estava disponível.

DESCONHECIDO ≠ NENHUM

O ERRO

Um “não sei” vira campo vazio, “nenhum” ou “não” no caminho até o modelo.

O TESTE

O desconhecido aparece **escrito**, **literalmente**, em todo contexto e em toda tela.

NÃO ENCONTREI ≠ NÃO EXISTE

O ERRO

Uma busca que não achou nada é tratada como prova de que a coisa não existe.

O TESTE

Toda negativa carrega o seu **escopo**: onde, como e quando se procurou.

CONTEXTO ≠ COMANDO

O ERRO

Um documento recuperado diz “ignore as instruções anteriores” — e o agente obedece.

O TESTE

Conteúdo que entra como **dado** nunca autoriza uma ação nem grava uma orientação permanente.

RECIBO ≠ EFEITO

O ERRO

"O comando retornou sucesso" é tratado como "a mudança aconteceu".

O TESTE

Observe a **pós-condição** por um canal independente de quem executou.

MAIS RECENTE ≠ ACEITO

O ERRO

A última versão é tratada como a aprovada.

O TESTE

Aceitação é um **ato registrado**, com autor e data — não uma consequência da ordem.

MÉDIA ≠ CRITÉRIO

O ERRO

"95% de acerto médio" esconde uma falha crítica que acontece em todas as execuções.

O TESTE

Relate o resultado **por dimensão**: uma falha crítica reprova, qualquer que seja a média.

A regra geral

Quando duas coisas parecem iguais, pergunte:

Que teste as distinguiria?

Se nenhum teste distingue, o sistema vai confundi-las — e o agente também.

> **PARA LEVAR**
>
> Cada confusão tem um modo de falha, um exemplo real e um teste. Sem o teste, a distinção é só opinião.

DE ONDE VEM ESTE CONTEÚDO

Do livro ***Contexto para Agentes de IA***, de André Antero de Carvalho.

Capítulo 1 e Apêndice E (catálogo de distinções e invariantes).

NA PRÓXIMA PARTE

O que um agente de IA *realmente* vê: a cadeia de restrição em sete níveis.